

Project 1 YOLO Baseline 实验总结（真实 Test 集）

1. 实验目标

本次实验面向课程 Project 1 的频谱识别任务，目标是搭建一个可复现、可运行、可汇报的 YOLO baseline，并在独立真实测试集上给出第一版检测结果。

当前 baseline 将频谱图视为目标检测任务处理，采用 Ultralytics YOLO 训练和推理。由于现有标签只提供频率范围、没有明确时间边界，因此本轮实验采用保守建模假设：

- 所有目标统一按单类 `signal` 处理。
- 每个目标框在时间轴方向覆盖整张图，仅根据频率范围确定纵向位置和高度。

这个设定的优点是可以先把完整链路跑通；缺点是标签表达能力偏弱，后续泛化能力可能受限。

2. 数据与预处理

数据来源包括：

- 训练集： `train_full.h5`
- 真实测试集： `test_full.h5`

经过预处理后，数据被转换为 YOLO 检测格式，并划分为：

- Train: 19200
- Val: 4800
- Test: 6000

其中测试集完全来自独立的 `test_full.h5`，没有使用训练集切分出的伪测试集。

真实测试集共包含 29372 个目标实例。当前标签统计显示：

- 框宽度恒为整图宽度
- 目标高度整体较小
- 长宽比普遍较大

这一现象与频谱图中条带状、窄带状信号的任务特征基本一致。

3. 模型与训练配置

本轮 baseline 使用轻量模型 `yolo11n.pt`，训练环境为 4 卡 3090 服务器中的单卡 GPU3。

主要训练配置如下：

- Model: `yolo11n.pt`
- Image size: 640
- Batch size: 16
- Epochs: 50
- Patience: 20
- Device: GPU3

训练过程中触发了 early stopping，因此实际训练在 **epoch 32** 结束，而不是跑满 50 轮。

4. 训练过程结果

根据 **results.csv** 复核：

- 最佳 fitness 与最佳 **mAP50-95** 出现在 **epoch 12**
- 最佳 **mAP50** 出现在 **epoch 14**

对应关键指标如下：

最佳 fitness / 最佳 mAP50-95 (epoch 12)

- Precision: 0.87967
- Recall: 0.63125
- mAP50: 0.69653
- mAP50-95: 0.59204

最佳 mAP50 (epoch 14)

- mAP50: 0.70082

从训练过程看，模型在验证集上是可以稳定收敛的，说明当前 YOLO 框架、数据转换和训练流程都已经打通，没有出现 NaN、OOM 或 checkpoint 缺失等工程性问题。

5. 真实测试集结果

使用最终 **best.pt** 在真实测试集上评测，得到如下 baseline 结果：

- Precision: 0.59541
- Recall: 0.32303
- mAP50: 0.35692
- mAP50-95: 0.23215

可以看到，验证集最优结果与真实测试集结果之间存在明显落差。这说明当前 baseline 虽然已经具备可运行性和可复现性，但泛化到独立测试集时仍然偏弱。

6. 推理现象与初步观察

在真实测试集上导出的推理样例中，模型已经能够识别出一部分明显的频谱信号，但仍存在以下问题：

- 对部分样本出现漏检
- 对弱信号或窄条带目标不够稳定
- 在一些样本上会直接出现零检测

在最初导出的 10 张样例中，共检测出 18 个 **signal**，其中有 3 张图为零检测。

2026-04-11 又补充导出了 50 张真实测试集预测图，统计结果如下：

- 50 张样例共检测出 80 个 **signal**
- 其中 17 张图出现零检测

这说明当前模型已经具备一定检测能力，但漏检比例仍然偏高，后续需要重点分析零检测样本和低置信度样本。

7. 模型大小与推理延迟

最终 `best.pt` 文件大小约为：

- 5.19 MB

当前记录到的推理延迟为 CPU 测试结果：

- Mean latency: 26.46 ms
- Median latency: 26.57 ms

说明该 baseline 在模型体积上比较轻量，符合“快速、轻量”这一 baseline 方向；但如果课程汇报需要 GPU 推理延迟，还需要额外补测 CUDA 条件下的延迟数据。

8. 当前结论

本轮实验已经完成了一个真实 test 集上的 YOLO baseline：

- 数据接入完成
- H5 到频谱图与 YOLO 标签的转换完成
- 训练、验证、推理和汇总链路完成
- 已获得独立真实测试集上的第一版 baseline 指标

因此，当前结果已经满足“可复现、可运行、可汇报”的阶段性目标。

9. 局限性

当前 baseline 仍有几个明显局限：

- 标签只有频率范围，没有时间边界，因此使用了“全宽框”近似
- 当前只做了单类 `signal` 检测，没有细分信号类型
- 验证集结果明显高于真实测试集结果，说明现有标签建模的泛化能力有限